IMPLEMENTASI BIG DATA UNTUK ANALISIS POPULARITAS FILM MENGGUNAKAN APACHE SPARK

Sains Data
Universitas Pembangunan Nasional "Veteran" Jawa Timur
2026

THE TEAM

Danisha Rizka Hapsari 24083010010

Aurel Maritza Maheswari Ahmad 24083010011

Maya Purnama Sari 24083010074

LATAR BELAKANG ANALISIS

- Industri film global semakin berkembang dan kompetitif.
- Platform digital menghasilkan data film dalam jumlah besar seperti rating, review, genre, dan popularitas film.
- Data tersebut dapat dianalisis untuk memahami tren dan preferensi penonton.
- Teknologi Big Data diperlukan untuk memproses dan menganalisis data film dalam skala besar secara efisien.

KONSEP BIG DATA

Big Data memiliki beberapa karakteristik utama:

- **Volume**

Jumlah data sangat besar, seperti dalam film dan komentar pengguna.

- **Velocity**

Data terus bertambah dari berbagai platform streaming.

- **Variety**

Data memiliki berbagai jenis seperti metadata film, rating, dan review pengguna.

Pemanfaatan Big Data memungkinkan analisis data dalam skala besar secara lebih efektif.

TEKNOLOGI YANG DIGUNAKAN

- **Apache Spark** → pemrosesan Big Data terdistribusi
- **PySpark** → analisis data menggunakan Python
- **Parquet** → format penyimpanan data Big Data
- **Python** → bahasa pemrograman utama
- **Jupyter Notebook** → lingkungan analisis interaktif
- **Hadoop Environment** → mendukung operasi file Spark
- **Git** → version control

ARSITEKTUR SISTEM BIG DATA

[DATA SCRAPING (From TMDB website)]

↓

[DATA INGESTION (Load ke PySpark DataFrame)]

↓

[DATA CLEANING: Handle missing values, Convert data types, Cleaning currency & duration, Split genre & stars]

↓

[DATA STORAGE (Parquet - Processed Layer)]

↓

[FEATURE ENGINEERING: Genre One Hot Encoding, Top Actors Encoding, Top Directors Encoding]

↓

[FEATURE STORAGE (Parquet - Feature Layer)]

↓

[BIG DATA ANALYTICS: Trend produksi film, Rating per genre, Actor & director influence, Correlation analysis]

↓

[INSIGHT & VISUALIZATION: Faktor film sukses, Genre terbaik, Aktor berpengaruh, Trend industri film]

DATASET YANG DIGUNAKAN

Dataset film dari TMDB berisi sekitar 9740 film dengan rentang tahun 1902–2026.

Atribut dalam dataset:

- Judul film
- Genre
- Tahun rilis
- Rating
- Votes
- Popularity
- Revenue

tipe data dari setiap kolom dalam DataFrame

```
In [8]:  movies_df.dtypes

Out[8]: [('Movie Name', 'string'),
         ('Year', 'int'),
         ('Certificate', 'string'),
         ('Duration', 'int'),
         ('Genre', 'string'),
         ('TMDB Rating', 'double'),
         ('Votes', 'bigint'),
         ('Director', 'string'),
         ('Stars', 'array<string>'),
         ('Grossed in $', 'double'),
         ('Plot', 'string'),
         ('Original Language', 'string'),
         ('Popularity', 'double'),
         ('TMDB ID', 'bigint'),
         ('IMDb ID', 'string')]
```

METODE ANALISIS

Metode analisis yang digunakan meliputi data cleaning, transformasi data, feature engineering, analisis deskriptif Big Data, dan analisis korelasi menggunakan Apache Spark. Analisis ini bertujuan mengidentifikasi faktor-faktor yang mempengaruhi rating film dan menghasilkan insight berbasis data

PROSES ANALISIS DATA

Tahapan analisis data dalam notebook:

- Dataset film diimpor menggunakan Apache Spark.
- Data disimpan dalam format Parquet untuk efisiensi penyimpanan dan pemrosesan.
- Dataset kemudian dimuat ke dalam Spark DataFrame.
- Data ditampilkan dan dianalisis menggunakan fungsi Spark seperti show().

Apache Spark memungkinkan pemrosesan dataset film dalam jumlah besar secara efisien melalui komputasi terdistribusi.

Kode Spark

```python
movies_df = spark.read.parquet("../data/processed/tmdb_movies_clean.parquet")
movies_df.cache()  # Cache karena akan dipakai beberapa kali
movies_df.show(5, truncate=False)
```

Python

```
+-----------------------+----+-----------+--------+------------------+----------+-----+-------------------+-----------------------------------------------
|Movie Name             |Year|Certificate|Duration|Genre             |TMDB Rating|Votes|Director           |Stars
+-----------------------+----+-----------+--------+------------------+----------+-----+-------------------+-----------------------------------------------
|The Shawshank Redemption|1994|R          |142     |Drama, Crime      |8.716      |29897|Frank Darabont     |[Tim Robbins, Morgan Freeman, Bob Gunton, William
|The Godfather          |1972|R          |175     |Drama, Crime      |8.688      |22579|Francis Ford Coppola|[Marlon Brando, Al Pacino, James Caan, Robert Duv
|The Godfather Part II  |1974|R          |202     |Drama, Crime      |8.572      |13674|Francis Ford Coppola|[Al Pacino, Robert Duvall, Diane Keaton, Robert D
|Schindler's List       |1993|R          |195     |Drama, History, War|8.566      |17195|Steven Spielberg   |[Liam Neeson, Ben Kingsley, Ralph Fiennes, Caroli
|12 Angry Men           |1957|NR         |97      |Drama             |8.555      |9809 |Sidney Lumet       |[Martin Balsam, John Fiedler, Lee J. Cobb, E.G. M
+-----------------------+----+-----------+--------+------------------+----------+-----+-------------------+-----------------------------------------------
only showing top 5 rows
```

Statistika Deskriptif

Statistika Deskriptif

[24]:

```python
movies_df.select(
    "Year", "Duration", "TMDB Rating", "Votes", "Grossed in $", "Popularity"
).describe().show()
```

```
+-------+------------------+------------------+------------------+------------------+------------------+------------------+
|summary|              Year|          Duration|       TMDB Rating|             Votes|       Grossed in $|        Popularity|
+-------+------------------+------------------+------------------+------------------+------------------+------------------+
|  count|              9740|              9740|              9740|              9740|              9740|              9740|
|   mean|2004.5041067761806|106.30369609856263| 6.731805338809012| 2101.797022587269|7.663537748131417E7|5.6489423408624315|
| stddev| 17.89469268409583| 23.13781367145706|0.6562514701588585|3360.4352092757545|1.626677457755464E8| 8.961339820259774|
|    min|              1902|                 2|             5.447|               300|               3.0|            0.0086|
|    max|              2026|               367|             8.716|             39092|      2.923706026E9|          699.9604|
+-------+------------------+------------------+------------------+------------------+------------------+------------------+
```

KEUNGGULAN APACHE SPARK

- Beberapa keunggulan Apache Spark dalam pemrosesan Big Data:
- Pemrosesan data lebih cepat dengan in-memory computing.
- Mendukung pemrosesan data dalam skala besar.
- Memiliki library machine learning (MLlib).
- Dapat terintegrasi dengan berbagai teknologi Big Data lainnya.

HASIL ANALISIS

Beberapa temuan utama dari analisis dataset film:

1. Hubungan Votes dan Revenue

Jumlah votes memiliki korelasi yang kuat dengan pendapatan film (revenue).
Film dengan votes tinggi cenderung menghasilkan pendapatan yang lebih besar.

2. Distribusi Rating Film

Rating film dalam dataset berkisar antara 5.4 hingga 8.7 dengan rata-rata sekitar 6.7, yang menunjukkan sebagian besar film memiliki kualitas yang cukup baik.

3. Genre Film Paling Banyak

Genre Drama merupakan genre paling dominan dalam dataset dengan lebih dari 4.500 film.

4. Film dengan Rating Tertinggi

Beberapa film klasik seperti The Shawshank Redemption dan The Godfather memiliki rating tertinggi dalam dataset.

5. Film Terlaris

Film Avatar (2009) menjadi film dengan pendapatan tertinggi dalam dataset dengan revenue sekitar $2.92 miliar.

Hasil analisis menunjukkan bahwa faktor seperti rating, jumlah votes, genre, dan popularitas memiliki pengaruh terhadap performa dan pendapatan film.

KESIMPULAN

- Analisis Big Data dapat digunakan untuk memahami faktor-faktor yang mempengaruhi popularitas film.
- Dataset film yang besar dapat diproses secara efisien menggunakan Apache Spark dengan pendekatan komputasi terdistribusi.
- Hasil analisis menunjukkan bahwa faktor seperti rating, jumlah votes, genre, dan revenue memiliki hubungan dengan tingkat popularitas film.
- Pemanfaatan teknologi Big Data dan machine learning dapat membantu industri film dalam memahami preferensi penonton serta mendukung pengambilan keputusan yang lebih baik.

REFERENSI

- [1] A. C. Bramantia, Desyanti, J. Hutahaean, dan E. W. Ambarsari, “Film Popularity Analysis through Combined K-Means Clustering and Gradient Boosted Trees,” International Journal of Informatics and Data Science, vol. 2, no. 2, pp. 46–54, 2025. DOI: 10.64366/ijids.v2i2.81
- [2] A. Manconi, M. Gnocchia, L. Milanesia, O. Marullob, dan G. Armanob, “Framing Apache Spark in Life Sciences,” Heliyon, vol. 9, no. 2, 2023. DOI: 10.1016/j.heliyon.2023.e13368
- [3] G. Chaitanya, Y. Hemanth, K. Koushik, P. Haneef, dan S. Pranav, “Movie Recommendation System Using Machine Learning and Spark,” International Journal of Innovative Science and Research Technology, vol. 8, no. 6, 2024. DOI: 10.5281/zenodo.10686713
- [4] L. He, “Predicting the Popularity of Movies with Social Media,” Proc. 2nd Int. Conf. Applied Psychology and Marketing Management, pp. 662–667, 2025. DOI: 10.5220/0014150300004942
- [5] L. Theodorakopoulos, A. Karras, dan G. A. Krimpas, “Optimizing Apache Spark MLlib: Predictive Performance of Large-Scale Models for Big Data Analytics,” Algorithms, vol. 18, no. 2, 2025. DOI: 10.3390/a18020074

REFERENSI

- [6] M. Arshad, C. W. Onn, A. Ahmad dan G. Mogwe, “Big data analytics and AI as success factors for online video streaming platforms,” Frontiers in Big Data, vol. 8, pp. 01-12, Februari 2025, doi:10.3389/fdata.2025.1513027.
- [7] S. Gheewala, S. Xu, dan S. Yeom, “ In-depth survey: deep learning in recommender systems—exploring prediction and ranking models, datasets, feature analysis, and emerging trends,” Springer, vol. 37, pp. 10875-10947, Maret 2025, doi:https://doi.org/10.1007/s00521-024-10866-z.
- [8] S. Zhan dan Y. Qiu, "Efficient Big Data Processing and Recommendation System Development with Apache Spark," Preprints, pp. 61-64, Juni 2025, doi:10.1109/ISBDAS64762.2025.11116871.
- [9] Z. Hasan, H. Jie Xing, dan M. Idrees Magray, “Big Data Machine Learning Using Apache Spark Mllib”, Mesopotamian Journal of Big Data, vol. 2022, pp. 1-11, Januari 2022, doi:10.58496/MJBD/2022/001.
- [10] Z. He, W. Liu, W. Guo, J. Qin, Y. Zhang, Y. Hu, dan R. Tang, “ A Survey on User Behavior Modeling in Recommender Systems,” Proceedings of the Thirty-Second International Joint Conference on Artificial Intelligence (IJCAI), pp. 1-9, Februari 2023, doi:https://doi.org/10.48550/arXiv.2302.11087.

THANK YOU