


PREDIKSI POPULARITAS DAN KESUKSESAN FILM MENGUNAKAN PENDEKATAN REGRESI DAN KLASIFIKASI PADA DATASET TMDB

BIG DATA



TEAM

**DANISHA RIZKA
HAPSARI**


24083010010

**AUREL MARITZA
MAHESWARI AHMAD**


24083010011

**MAYA PURNAMA
SARI**

24083010074



LATAR BELAKANG



Industri film global menghasilkan ribuan judul setiap tahun, namun tidak semua film berhasil secara komersial maupun kritikal.

Pertanyaan utama: apa yang membedakan film yang laku dari yang tidak?

Prediksi gross revenue film berdasarkan karakteristik sebelum rilis.

Klasifikasi film sebagai hit atau flop menggunakan machine learning.

Identifikasi tren dan faktor kunci kesuksesan dari 19.000+ data film.



TUJUAN



1.

**FAKTOR APA YANG
PALING
MEMPENGARUHI
GROSS REVENUE
SEBUAH FILM?**

2.

**APAKAH SEBUAH
FILM BISA
DIPREDIKSI SEBAGAI
HIT ATAU FLOP
SEBELUM DIKETAHUI
HASILNYA?**

3.

**BAGAIMANA TREN
POPULARITAS FILM
BERUBAH
BERDASARKAN
GENRE, BAHASA, DAN
TAHUN?**

VOLUME





DATA & PRE-PROCESSING

- Sumber: scraping TMDB
Data bersih: 19.017 film, 16 variabel
- Labeling hit/flop:
hit = gross $\geq$ \$50M atau rating $\geq$ 7.5
flop = gross $<$ \$10M dan rating $<$ 5.5

VARIABILITY

EKSPLORASI DATA





Genre Drama mendominasi dataset TMDB dengan 8.246 film, jauh lebih banyak dibanding genre lainnya. Comedy dan Thriller menempati posisi kedua dan ketiga.

Median pendapatan film tertinggi terjadi pada dekade 2000-an sebesar USD 39 juta. Setelah itu, median pendapatan cenderung mengalami penurunan.

VARIABILITY

EKSPLORASI DATA



Film berbahasa Jepang memperoleh rata-rata rating tertinggi (6,45), menunjukkan tingkat apresiasi penonton yang lebih baik dibanding bahasa lainnya.

Terdapat hubungan positif antara jumlah votes dan pendapatan film, di mana film dengan votes lebih banyak cenderung menghasilkan revenue yang lebih tinggi.

VARIABILITY

TREN & INSIGHT UTAMA ?

Genre Action & Animasi

Paling konsisten menghasilkan hit, proporsi film laku jauh di atas rata-rata.

Film Non-English Makin Relevan

Korea & Jepang memiliki rata-rata rating tertinggi meski jumlah film lebih sedikit.

Revenue Sangat Skewed

10% film teratas menyumbang mayoritas total gross.

Tren Revenue Naik Post-2000

Median gross meningkat signifikan di era 2000-an.

Votes = Prediktor Terkuat

Film dengan votes tinggi hampir selalu masuk kategori hit, terlepas dari genre.

Rating $\neq$ Revenue Tinggi

Film artsy dapat rating 8+ tapi gross rendah.

REGRESI

PREDIKSI GROSS REVENUE

Perbandingan 6 Model

VALUE

Gradient Boosting ★

$R^2=0.62$

XGBoost

$R^2=0.61$

LightGBM


$R^2=0.61$

Random Forest

$R^2=0.58$

Ridge

$R^2=0.48$



Model berbasis boosting menunjukkan performa prediksi revenue yang lebih baik dibanding model lainnya.

REGRESI


VALUE

PREDIKSI GROSS REVENUE



Perbandingan 6 Model

Perbandingan Semua Model — Prediksi Gross Revenue




Gradient Boosting menjadi model terbaik dengan nilai R^2 tertinggi dan error terendah.

REGRESI

PREDIKSI GROSS REVENUE

VALUE

Prediksi dalam Skala Dollar




Prediksi model mengikuti pola data aktual, meskipun masih terdapat selisih pada film dengan revenue sangat tinggi.

REGRESI

PREDIKSI GROSS REVENUE

VALUE

Feature Importance




Votes dan Tahun Rilis merupakan faktor yang paling berpengaruh terhadap revenue film.

KLASIFIKASI HIT VS FLOP

VALUE

Label Distribution & SMOTE




Data hit dan flop tidak seimbang, sehingga SMOTE digunakan untuk menyeimbangkan data latih.

KLASIFIKASI HIT VS FLOP

VALUE

Perbandingan Semua Model Klasifikasi




XGBoost memberikan performa klasifikasi terbaik pada hampir seluruh metrik evaluasi.

KLASIFIKASI HIT VS FLOP

VALUE

Classification Report (XGBoost)




Model XGBoost mampu mengidentifikasi film hit dengan sangat baik serta meningkatkan deteksi film flop.

KLASIFIKASI HIT VS FLOP

VALUE

Feature Importance & SHAP



Film bergenre family menjadi faktor utama yang menentukan status hit atau flop suatu film.

VALIDITY

AKURASI & KETEPATAN ANALISIS

Anti Data Leakage

TMDB Rating & Grossed sengaja tidak dipakai sebagai fitur klasifikasi, keduanya langsung mendefinisikan label, sehingga kalau dipakai model dapat skor sempurna tapi tidak valid.

SMOTE Hanya di Train Set

Resampling dilakukan setelah split — test set tetap mencerminkan distribusi asli dunia nyata (96% hit, 4% flop), bukan distribusi artifisial.

VALIDITY

AKURASI & KETEPATAN ANALISIS

Metrik Tepat untuk Imbalance

Evaluasi utama memakai AUC & F1-Flop, bukan Accuracy — karena accuracy 96% bisa dicapai hanya dengan menebak semua film sebagai 'hit'.

Log-Transform Target Regresi

Gross revenue sangat skewed (right-tail panjang) — transformasi $\log_{1p}$ membuat distribusi lebih normal sehingga model regresi bekerja lebih optimal.

VALIDITY

AKURASI & KETEPATAN ANALISIS

Labeling Berbasis Domain Knowledge

Hit = gross $\geq$ \$50M atau rating $\geq$ 7.5 |
Flop = gross $<$ \$10M dan rating $<$ 5.5 —
zona abu-abu di-drop agar model lebih
tegas, bukan bias.

Cross-Validation 5-Fold

Semua model dievaluasi dengan stratified
5-fold CV untuk memastikan performa
tidak hanya baik di satu split tertentu.

KESIMPULAN

Gradient Boosting adalah model terbaik untuk prediksi revenue dengan $R^2=0.62$. Menjelaskan 62% variansi pendapatan film

XGBoost unggul untuk klasifikasi hit/flop dengan $AUC=0.98$, meski data sangat tidak seimbang

Votes dan Popularity adalah fitur terpenting, film yang banyak dibicarakan cenderung laku secara komersial

Genre Action & Animasi memiliki rasio hit tertinggi; film Non-English (Korea, Jepang) semakin relevan secara global



THANK YOU